

2019年全国大学生数学建模竞赛赛题讲评 与经验交流会




D: 空气质量数据的校准

崔恒建

首都师范大学

北京师范大学珠海校区, 2019.11.23



题 目

空气污染对生态环境和人类健康危害巨大，通过对“两尘四气”（PM_{2.5}、PM₁₀、CO、NO₂、SO₂、O₃）浓度的实时监测可以及时掌握空气质量，对污染源采取相应措施。

虽然国家监测控制站点（国控点）对“两尘四气”有监测数据，且较为准确，但因为国控点的布控较少，数据发布时间滞后较长且花费较大，无法给出**实时空气质量的监测和预报**。

- 某公司自主研发的微型空气质量检测仪，花费小，可对某一地区空气质量进行实时网格化监控，并同时监测温度、湿度、风速、气压、降水等气象参数。



由于所使用的电化学气体传感器在长时间使用后会产生一定的零点漂移和量程漂移，非常规气态污染物（气）浓度变化对传感器存在交叉干扰，以及天气因素对传感器的影响，在国控点近邻所布控的自建点上，同一时间微型空气质量检测仪所采集的数据与该国控点的数据值存在一定的差异。

需要利用国控点每小时的数据对国控点 近邻的自建点数据进行校准。

附件1.CSV和附件2.CSV分别提供了一段时间内某个国控点每小时的数据和该国控点近邻的一个自建点数据（相应于国控点时间且间隔在5分钟内），各变量单位见附件3。

dxs.moe.gov.cn

请建立数学模型研究下列问题：

1. 对自建点数据与国控点数据进行**探索性数据分析**。
2. 对导致自建点数据与国控点数据造成**差异的因素**进行分析。
3. 利用国控点数据，建立数学模型对自建点数据进行**校准**。

思路



校准目的:

实时网格化监控预测，即 T 时刻没有国控点数据，需要通过

T 时刻自建点数据（两尘四气+气象）

预测 T 时刻国控点数据

中国大学生在线
dxs.moe.gov.cn

针对目的校准建模:

寻找T之前

自建点数据（两尘四气+气象）
与国控点数据的对应规律，即

ZJD（两尘四气+气象） ~ GKD



数据分析
影响因素分析

中国大学生在线
dxs.moe.gov.cn

■ 探索性数据分析

考察学生在数学建模过程中对实验数据的认识处理和评估的能力，包括：

数据的预处理

数据的可视化

简单的数据相关性展示

为数学建模打下基础。

中国大学生在线
dxs.moe.gov.cn

国控点数据是小时数据，自建点数据是分钟数据，需要对应处理（新）

平滑处理：

将自建点的分钟数据在单位小时附近
进行平均或加权平均

扩充处理：

将国控点数据按自建点数据的时间点
进行优化插值

中国大学生在线
dxs.moe.gov.cn

数据的可视化:

散点图、直方图等

简单的数据相关性展示:

数据的协方差阵、
线性相关系数阵等

中国大学生在线
dxs.moe.gov.cn

■ 影响因素分析

对处理后的自建点数据（前6个变量）与对应的国控点数据以及温湿度、降水、风速、压强数据进行多元数据的相关分析，寻找引起自建点与国控点数据差异的影响因素。

可通过简单的类间相关展示和量化计算，如线性模型等。

■ 数据的校准模型

用目标数据校对有误差数据

是第1、2问的深入，需**分别**建立6个国控点变量与自建点前6个校对变量以及环境变量（风速、温度、湿度、降水、压强等）之间的校准模型：

有误差数据 目标数据
ZJD（两尘四气6+气象5） ~ GKD

中国大学生在线
dxs.moe.gov.cn

例如：

多元线性回归模型；
前馈、**BP**神经网络模型

- 对校对误差进行分析
■ 给出量化评判结果。

中国大学生在线
dxs.moe.gov.cn

解 题

1. 探索性数据分析

- 删除有缺失和重复数据，整理出有效数据为4144小时及对应的小时数据。
- 自建点 230152 分钟数据

中国大学生在线
dxs.moe.gov.cn

a. 累积小时与数据平均

以国控点的小时数据为对应匹配目标（4144个小时数据），将数据按累积小时进行自然排序。对给定的小时，将自建点在对应此小时的前后半小时内的分钟数据进行平均（或加权平均），即得到自建点对应的国控点所有的小时数据。

b. 插值扩充数据

将国控点线性或二次插值，并与自建点对应，230152个。

■ 内部变量之间数据分析

相关性展示，统计指标计算等
直方图，矩形图等展示


中国大学生在线
dxs.moe.gov.cn

a. 国控点和处理后的自建点数据的样本相关阵:



$$R_{gkd} = \begin{bmatrix} 1.000 & 0.808 & 0.661 & 0.258 & 0.290 & -0.262 \\ 0.808 & 1.000 & 0.574 & 0.305 & 0.318 & -0.167 \\ 0.661 & 0.574 & 1.000 & 0.298 & 0.315 & -0.267 \\ 0.258 & 0.305 & 0.298 & 1.000 & -0.341 & -0.254 \\ 0.290 & 0.318 & 0.315 & -0.341 & 1.000 & -0.285 \\ -0.262 & -0.167 & -0.267 & -0.254 & -0.285 & 1.000 \end{bmatrix}$$

$$R_{zjd} = \begin{bmatrix} 1.000 & 0.959 & 0.256 & 0.327 & 0.074 & -0.028 & -0.240 & 0.212 & 0.012 & -0.338 & 0.386 \\ 0.959 & 1.000 & 0.353 & 0.353 & 0.064 & 0.078 & -0.239 & 0.322 & 0.096 & -0.409 & 0.407 \\ 0.256 & 0.353 & 1.000 & 0.280 & 0.217 & 0.529 & -0.177 & -0.126 & 0.159 & 0.248 & 0.022 \\ 0.327 & 0.353 & 0.280 & 1.000 & 0.110 & -0.014 & -0.397 & 0.065 & -0.327 & -0.159 & 0.272 \\ 0.074 & 0.064 & 0.217 & 0.110 & 1.000 & -0.046 & -0.086 & 0.019 & -0.062 & -0.046 & 0.035 \\ -0.028 & 0.078 & 0.529 & -0.014 & -0.046 & 1.000 & 0.092 & -0.120 & 0.259 & 0.370 & -0.349 \\ -0.240 & -0.239 & -0.177 & -0.397 & -0.086 & 0.092 & 1.000 & 0.096 & 0.065 & -0.062 & -0.315 \\ 0.212 & 0.322 & -0.126 & 0.065 & 0.019 & -0.120 & 0.096 & 1.000 & 0.235 & -0.850 & 0.151 \\ 0.012 & 0.096 & 0.159 & -0.327 & -0.062 & 0.259 & 0.065 & 0.235 & 1.000 & -0.143 & 0.084 \\ -0.338 & -0.409 & 0.248 & -0.159 & -0.046 & 0.370 & 0.062 & -0.850 & -0.143 & 1.000 & -0.491 \\ 0.386 & 0.407 & 0.022 & 0.272 & 0.035 & -0.349 & -0.315 & 0.151 & 0.084 & -0.491 & 1.000 \end{bmatrix}$$

- 相关阵Rgkd和Rzjd以热力图:



■ 自建点和国控点观测数据散布图矩阵:




b. 国控点和处理后的自建点数据的
样本相关阵:



$$R_{gkd} = \begin{bmatrix} 1.000 & 0.741 & 0.666 & 0.330 & 0.296 & -0.272 \\ 0.741 & 1.000 & 0.518 & 0.339 & 0.301 & -0.154 \\ 0.666 & 0.518 & 1.000 & 0.400 & 0.282 & -0.281 \\ 0.330 & 0.339 & 0.400 & 1.000 & -0.212 & -0.372 \\ 0.296 & 0.301 & 0.282 & -0.212 & 1.000 & -0.189 \\ -0.272 & -0.154 & -0.281 & -0.372 & -0.189 & 1.000 \end{bmatrix}$$

$$R_{zjd} = \begin{bmatrix} 1.000 & 0.957 & 0.193 & 0.321 & 0.068 & -0.078 & -0.130 & 0.281 & 0.026 & -0.399 & 0.358 \\ 0.957 & 1.000 & 0.275 & 0.332 & 0.058 & 0.011 & -0.127 & 0.377 & 0.092 & -0.456 & 0.369 \\ 0.193 & 0.275 & 1.000 & 0.245 & 0.210 & 0.477 & -0.088 & -0.174 & 0.177 & 0.290 & -0.049 \\ 0.321 & 0.332 & 0.245 & 1.000 & 0.109 & -0.077 & -0.251 & 0.053 & 0.305 & -0.157 & 0.249 \\ 0.068 & 0.058 & 0.210 & 0.109 & 1.000 & -0.047 & -0.049 & 0.025 & -0.055 & -0.048 & 0.033 \\ -0.078 & 0.011 & 0.477 & -0.077 & -0.047 & 1.000 & 0.112 & -0.166 & 0.247 & 0.429 & -0.450 \\ -0.130 & -0.127 & -0.088 & -0.251 & -0.049 & 0.112 & 1.000 & 0.058 & 0.034 & 0.052 & -0.211 \\ 0.281 & 0.377 & -0.174 & 0.053 & 0.025 & -0.166 & 0.058 & 1.000 & 0.112 & -0.840 & 0.144 \\ 0.026 & 0.092 & 0.177 & 0.305 & -0.055 & 0.247 & 0.034 & 0.112 & 1.000 & -0.049 & 0.060 \\ -0.399 & -0.456 & 0.290 & -0.157 & -0.048 & 0.429 & 0.052 & -0.840 & -0.049 & 1.000 & -0.515 \\ 0.358 & 0.369 & -0.049 & 0.249 & 0.033 & -0.450 & -0.211 & 0.144 & 0.060 & -0.515 & 1.000 \end{bmatrix}$$

■ 相关阵Rgkd和Rzjd以热力图:





















■ 自建点和国控点观测数据散布图矩阵:



- (i). 在自建点和国控点数据中，PM25和PM10均具有较强的相关性.
- (ii). 在自建点数据中，CO和O3具有较强相关性，气压与温度负相关，其他各个变量之间相关性不大.
- (iii). 在国控点数据中，CO与PM25和PM10均具有较强的相关性，其他各个变量之间的相关性较弱.

- 所给数据和匹配的小时数据（a）是时间序列数据，六个变量的时间序列图（b类似）











2. 导致自建点数据与国控点数据造成差异的因素分析

- **校准：**用国控点的数据校准自建点数据，使得自建点数据在校准（调整）后更接近国控点的数据，目的是使用未来自建点数据来预测国控点数据。
- 为更好地建模，需要分析自建点前6个变量和国控点6个变量之间差异性因素。

国控点与自建点数据几个重要变量之间的散点图



- 发现国控点和自建点的PM25、PM10、O3具有较强相关性,
- 其他各个变量之间的散点图这里不再给出。它们的Pearson 相关系数计算公式:

$$r = \frac{\sum_{i=1}^n (x_i - \bar{x})(y_i - \bar{y})}{\sqrt{\sum_{i=1}^n (x_i - \bar{x})^2 \sum_{i=1}^n (y_i - \bar{y})^2}}$$

中国大学生在线
dxs.moe.gov.cn

■ 计算结果:

变量	PM25	PM10	CO	NO2	SO2	O3
PM25	0.920	0.681	0.607	0.173	0.283	-0.384
PM10	0.874	0.653	0.582	0.080	0.390	-0.451
CO	0.311	0.331	0.335	-0.107	0.514	0.027
NO2	0.320	0.312	0.384	0.383	0.299	-0.518
SO2	0.086	0.117	0.103	0.103	0.037	-0.074
O3	0.064	0.154	0.095	-0.213	0.367	0.422
Windspeed	-0.244	-0.176	-0.318	-0.348	-0.190	0.395
Pressure	0.088	0.035	-0.075	-0.107	0.192	-0.437
Rain	-0.069	-0.087	0.076	-0.144	0.271	-0.120
Temperature	-0.168	-0.036	-0.055	-0.011	-0.101	0.676
Humidity	0.180	-0.083	0.220	-0.130	0.110	-0.611

表 1: 国控点和自建点各个变量之间的相关系数

- 从相关系数表1看出:

国控点PM25和自建点的PM25、PM10;
国控点PM10, CO和自建点的PM25、PM10;
SO2和CO具有较强的相关性; O3与NO2呈负
相关;

同时风速与PM25、CO、PM10、NO2、
SO2 呈负相关, 与O3呈正相关;

温度与O3呈正相关。

- 自建点6个变量的差异（或校准）可能更大地依赖国控点：

PM25、PM10、CO、O3、

Windspeed、Temperature

的变化。

中国大学生在线
dxs.moe.gov.cn

3. 利用国控点数据建立自建点 数据校准数学模型

利用国控点数据，建立数模对自建点数据进行校准，基于上述相关性分析，选择如下两种模型：

(1). 多元线性回归 (Multivariate Linear Regression, MLR) 模型

(2). 前馈 (或BP) 神经网络 (BPNN, FNN) 模型

- 建校准模型，以自建点各变量数据作为输入，国控点数据作为输出。
- 将自建点校对的6个主要空气质量变量（+5个气象因子变量）与相应国控点的每一个变量尽量接近，分别建立多元回归模型或NN模型。

■ 3.1. 多元线性回归模型

以PM25为例（其余类似），建立MLR
对自建点的数据进行校对，设 $PM25_{jd}$ 为自建
点PM25的校对值，则有：

$$PM25_{jd} = \beta_0 + \beta_1 PM25_{zjd} + \beta_2 CO_{zjd} + \cdots + \beta_{11} Humidity$$


中国大学生在线
dxs.moe.gov.cn

- 由于自建点PM25的校对值应尽量接近国控点PM25的值，因而：

$$PM25_{gkd} = PM25_{jd} + \varepsilon$$

故所建立的校准的MLR模型为：

$$PM25_{gkd} = \beta_0 + \beta_1 PM25_{zjd} + \beta_2 CO_{zjd} + \dots + \beta_{11} Humidity + \varepsilon$$



- 对MLR模型，利用处理后的小时数据(a)和最小二乘方法求解，获得参数估计，从而得到自建点PM25的校对值
- 数据预留下最后200个数据作为预测用

OLS方法基本汇总 (PM25为例)

Model:	OLS	Adj. R-squared:	0.902
Dependent Variable:	PM2.5	AIC:	2.979e+04
Date:	2019-07-24 17:06	BIC:	2.986e+04
No. Observations:	3937	Log-Likelihood:	-14881.
Df Model:	11	F-statistic:	3306.
Df Residuals:	3925	Prob (F-statistic):	0.00
R-squared:	0.903		
Omnibus:	1038.679	Durbin-Watson:	0.655
Prob(Omnibus):	0.000	Jarque-Bera (JB):	6085.130
Skew:	1.125	Prob(JB):	0.000
Kurtosis:	8.659	Condition No.:	3.28e+05

MLR模型的各个参数（PM25为例）



	Coef.	Std.Err.	t	P> t	[0.025	0.975]
const	511.7575	53.057	9.645	0.000	407.736	615.779
PM2.5	0.7743	0.020	38.171	0.000	0.734	0.814
PM10	0.0345	0.012	2.900	0.004	0.011	0.058
CO	7.8625	1.408	5.584	0.000	5.102	10.623
NO2	0.0717	0.008	8.526	0.000	0.055	0.088
SO2	-0.0034	0.010	-0.343	0.732	-0.023	0.016
O3	0.0085	0.008	1.002	0.316	-0.008	0.025
Windspeed	-2.8443	0.568	-5.008	0.000	-3.958	-1.731
Pressure	-0.4838	0.051	-9.454	0.000	-0.584	-0.383
Rain	-0.0279	0.002	-11.606	0.000	-0.033	-0.023
Temperature	-0.2284	0.062	-3.691	0.000	-0.350	-0.107
Humidity	-0.3484	0.012	-28.779	0.000	-0.372	-0.325

MLR模型的各个变量校准与预测误差







a

变量	PM25	CO	PM10	NO2	SO2	O3
拟合_MSE	112.385	0.125	869.950	302.276	230.200	488.978
预测_MSE	59.499	0.270	411.138	185.088	606.378	1802.483
拟合_MAE	7.368	0.128	14.880	13.224	10.176	16.763
预测_MAE	5.896	0.317	16.265	10.525	20.674	34.704

b


变量	PM25	CO	PM10	NO2	SO2	O3
拟合_MSE	146.602	0.122	1371.329	314.846	166.200	576.150
预测_MSE	70.049	0.2700	348.811	110.165	267.300	1675.990
拟合_MAE	8.106	0.079	16.467	13.568	7.903	18.243
预测_MAE	6.483	0.245	15.0140	8.204	13.676	33.828

■ 用剩余200数据点对国控点各个变量的预测图



3.2. 前馈神经网络模型

不同的神经网络模型有着不同的网络连接拓扑结构，一种比较直接的拓扑结构是前馈神经网络(Feedforward Neural Network, FNN)。









中国大学生在线
dxs.moe.gov.cn

■ 采用**FNN**设置的具体参数为:

输入层:	11
隐藏层:	3 (PM25节点 5, 3, 5, ...)
输出层:	1
激活函数:	RELU (修正线性单元)
优化算法:	Adma
正则化因子:	$\alpha = 0.001$
学习率:	0.01
最大迭代次数:	1000
误差率:	1e-8

中国大学生在线
dxs.moe.gov.cn

计算结果如下:



FNN模型的校准与预测误差

a

变量	PM25	CO	PM10	NO2	SO2	O3
拟合_MSE	112.662	0.1279	869.954	214.959	94.090	378.725
预测_MSE	60.008	0.0676	199.980	137.625	248.0748	1568.720
拟合_MAE	7.532	0.2757	21.951	14.880	6.373	14.6280
预测_MAE	6.153	0.1972	10.862	16.265	11.605	32.8498

b

变量	PM25	CO	PM10	NO2	SO2	O3
拟合_MSE	126.486	0.08467	1339.8457	189.495	50.6815	403.9404
预测_MSE	66.5066	0.1387	211.3354	109.1453	87.8575	973.189
拟合_MAE	7.2197	0.21899	19.3407	9.5519	4.4654	15.0048
预测_MAE	6.8143	0.27845	12.1479	8.5964	7.5678	24.5716

评阅总结

学生本赛题的建模方法以线性回归和神经网络方法为主。

第一问

优点:

- 去除重复值、异常值等。
- 数据对应方法:
 - 1) 将自建点的数据进行压缩(数据平均)与国控点的小时数据对应;
 - 2) 将国控点的数据进行优化插值(扩充数据)与自建点的数据对应。

- 常用统计指标、相关系数的计算；时间序列、散点图、Pearson相关矩阵图的可视化等。

不足：

- 过于面面俱到，可视化与指标计算的目的性不明确。

第二问

优点:

- 用对应的差值与气象因子进行线性回归或检验，计算相关系数等来寻找影响因素。
- 考虑有交互效应的线性模型。

不足：只简单利用差值来寻找气象因子因素，而忽略两尘四气的影响。

第三问

优点:

- 利用多元线性回归方法:

- 1) 利用校准因子（因变量）对两尘四气+气象因子（自变量）；

- 2) 利用两尘四气单的因子或差值（因变量）对气象因子（自变量）。

- 神经网络网络方法（BP）

- SVM方法

不足:

- 校对目的不明确, 仅仅利用两尘四气的单因子或差值(因变量)对气象因子(自变量)进行回归分析;
- 神经网络方法调参不够仔细;
- 缺少模型比较以及校对误差的比较。



谢谢!

中国大学生在线
dxs.moe.gov.cn

dxs.moe.gov.cn