



古代玻璃制品的成分分析与鉴别

——CUMCM2022C

北京大学 邓明华





古代玻璃制品的成分分析与鉴别

1. 题目及命题背景

2. 评阅要点

3. 解题思路

4. 评阅综述

中国大学生在线
dxs.moe.gov.cn



1. 题目及命题背景

- 本题由西安建筑科技大学鲁萍老师出题，题目来源于她与考古专家的合作项目；
- **丝绸之路**是古代中西方文化交流的通道，其中玻璃是早期贸易往来的宝贵物证。
- 早期的玻璃在西亚和埃及地区常被制作成珠形饰品传入我国，我国古代玻璃吸收其技术后在本土就地取材制作，因此与外来的玻璃制品**外观相似，但化学成分却不相同**。



古代玻璃的化学背景

- 玻璃的主要原料是石英砂，主要化学成分是二氧化硅（ SiO_2 ）。由于纯石英砂的熔点较高，为了降低熔化温度，在炼制时需要添加助熔剂。古代常用的助熔剂有草木灰、天然泡碱、硝石和铅矿石等，并添加石灰石作为稳定剂，石灰石煅烧以后转化为氧化钙（ CaO ）。添加的助熔剂不同，其主要化学成分也不同。例如，铅钡玻璃在烧制过程中加入铅矿石作为助熔剂，其氧化铅（ PbO ）、氧化钡（ BaO ）的含量较高，通常被认为是我国自己发明的玻璃品种，楚文化的玻璃就是以铅钡玻璃为主。钾玻璃是以含钾量高的物质如草木灰作为助熔剂烧制而成的，主要流行于我国岭南以及东南亚和印度等区域。



风化状态

- 古代玻璃极易受埋藏环境的影响而风化。在风化过程中，内部元素与环境元素进行大量交换，导致其成分比例发生变化，从而影响对其类别的正确判断。如图1的文物标记为表面**无风化**，表面能明显看出文物的颜色、纹饰，但不排除局部有较浅的风化；图2的文物标记为表面风化，表面大面积灰黄色区域为风化层，是**明显风化**区域，紫色部分是一**般风化**表面。在部分风化的文物中，其表面也有未风化的区域。



图1 未风化的蜻蜓眼玻璃珠样品



图2 风化的玻璃棋子样品



数据说明

- 现有一批我国古代玻璃制品的相关数据，考古工作者依据这些文物样品的化学成分和其他检测手段已将其分为**高钾玻璃和铅钡玻璃两种类型**。附件表单1给出了这些文物的分类信息，附件表单2给出了相应的主要成分所占比例（空白处表示未检测到该成分）。
- 这些**数据的特点是成分性**，即各成分比例的累加和应为**100%**，但因检测手段等原因可能导致其成分比例的累加和非**100%**的情况。本题中将成分比例累加和介于**85%~105%**的数据视为有效数据。



问题1: 对这些玻璃文物的表面风化与其玻璃类型、纹饰和颜色的关系进行分析；结合玻璃的类型，分析文物样品表面有无风化化学成分含量的统计规律，并根据风化点检测数据，**预测其风化前的化学成分含量**。

问题3: 对附件表单3中未知类别玻璃文物的化学成分进行分析，**鉴别其所属类型**，并对分类结果的敏感性进行分析。

问题2: 依据附件数据分析高钾玻璃、铅钡玻璃的**分类规律**；对于每个类别**选择合适的化学成分**对其进行**亚类划分**，给出具体的划分方法及划分结果，并对分类结果的合理性和敏感性进行分析。

问题4: 针对不同类别的玻璃文物样品，分析其化学成分之间的**关联关系**，并比较不同类别之间的化学成分**关联关系的差异性**。



2. 评阅要点

- 本题通过对古代玻璃制品的化学成分数据分析，研究有无风化玻璃制品成分的变化规律，以及高钾、铅钡两种玻璃类型的化学成分统计规律，并探索亚分类的方法，进而可以依据未知分类的文物化学成分对文物进行准确的分类。本题数据的主要特点是成分性，即各化学成分比例的累加和应100%，具有定和约束，在统计学上称为“成分数据”。同时由于定和约束，成分数据各变量之间具有明显的共线性，使得常规的统计分析方法失效。通常需要通过适当的变换解决这类问题，比如：中心对数比变换(Centered Log-ratio, CLR)等。



问题1

- 对玻璃文物表面风化与其类型、纹饰和颜色的关系进行分析，这是离散变量和连续变量的相关性分析、由风化点和未风化点的检测数据预测其风化前的化学成分含量的问题，需要分析风化与未风化两个总体的统计规律，通过总体之间的匹配进行预测。
 - (1) 数据预处理：无效数据去除，应避免对有效数据的删除；数据误差修正。
 - (2) 如果使用卡方检验，应注意其适用条件。
 - (3) 由于没有风化前后匹配的数据，采用简单的线性回归模型是不合适的。
 - (4) 应该充分考虑到成分数据的特点，简单地取均值不满足成分性的约束。



问题2

- 依据表单1、表单2数据，分析高钾玻璃、铅钡玻璃的分类规律，这是一个有监督的分类问题；亚类划分是一个无监督分类问题；敏感性分析是考察分类方法的稳定性。
 - (1) 按高钾、铅钡两大类或者按四类（高钾无风化、高钾风化、铅钡无风化、铅钡风化）进行分类规律的讨论均可。
 - (2) 对分类效果应给出相应的评价；对亚类划分结果应能明确阐述其亚类特征，解释其重要成分。
 - (3) 鼓励考虑成分变量的选择对分类结果的影响。
 - (4) 应该充分考虑到成分数据特点，关注样本之间距离的合理性。



问题3

- 对附件表单3中未知类别玻璃文物的化学成分进行分析，鉴别其所属类型，这是一个判别问题。敏感性分析是考察判别方法的稳定性。
 - (1) 基于高钾、铅钡两类或者按四类（高钾无风化、高钾风化、铅钡无风化、铅钡风化）进行判别均可。
 - (2) 应该充分考虑到成分数据特点，关注判别方法的合理性。
 - (3) 参考结果：

文物编号	A1	A2	A3	A4	A5	A6	A7	A8
分类	高钾	铅钡	铅钡	铅钡	铅钡	高钾	高钾	铅钡



问题4

- 针对不同类型的玻璃文物样品，分析其化学成分之间的关联关系，并比较不同类别之间的化学成分关联关系的差异性，这是一个化学成分的相关性分析问题。
 - (1) 采用相关系数法仅能反映其线性相关关系，如能考虑非线性关联关系是值得鼓励的。
 - (2) 由于成分数据的特点，考虑成分性与否对发现和确定各成分间关联关系的影响是显著的。



问题4

- 针对不同类型的玻璃文物样品，分析其化学成分之间的关联关系，并比较不同类别之间的化学成分关联关系的差异性，这是一个化学成分的相关性分析问题。
 - (1) 采用相关系数法仅能反映其线性相关关系，如能考虑非线性关联关系是值得鼓励的。
 - (2) 由于成分数据的特点，考虑成分性与否对发现和确定各成分间关联关系的影响是显著的。





3. 解题思路

- 成分数据特点：中心对数比变换，将成分数据定和约束空间变换到欧氏空间，然后再利用常规的统计或者机器学习方法进行处理；
- 缺少风化前后同时都有测量的数据，是无配对样本的预测问题：只能退而求其次，采用分布匹配的思想进行预测；
- 成分数据相关系数有偏负的倾向，需要充分考虑成分性特点。



成分数据(Compositional Data)

- 成分数据各分量受到定和限制，落在单纯形空间 S 上

$$S = \left\{ (x_1, \dots, x_p), x_j > 0, \sum_{i=1}^p x_i = 1 \right\}$$

- 一般需要将 p 维数据从单纯形空间变换到 $p-1$ 维欧氏空间

- 中心对数比变换(Centered Log-ratio, CLR)

$$z_i = \ln \frac{x_i}{g(x)}, i = 1, 2, \dots, p. \quad g(x) = (x_1 x_2 \cdots x_p)^{1/p}$$

- 等距对数比变换(Isometric Log-ratio, ILR)

$$z_j = \sqrt{\frac{p-j}{p-j+1}} \ln \frac{x_j}{(\prod_{k=j+1}^p x_k)^{1/(p-j)}}, j = 1, 2, \dots, p-1$$



成分数据(Compositional Data)




Fig. 1 Composition of sand, silt, and clay in agricultural soils of Europe. Ternary diagram **a**, representation in ilr coordinates **b**


Mehmet Can Mert, Peter Filzmoser, Karel Hron. Error Propagation in Isometric Log-ratio Coordinates for Compositional Data: Theoretical and Practical Considerations. Math Geosci DOI 10.1007/s11004-016-9646-x, 2016.



问题1-1（参考）

➤ 风化与玻璃类型、纹饰和颜色的关系

➤ 卡方检验多出现期望值小于5，结果可能不准，用Fisher精确检验加以验证；



Pearson's Chi-squared test with Yates' continuity correction

X-squared = 5.4518, df = 1, p-value = 0.01955

是否风化

玻璃珠类型 风化 无风化

高钾 10.55172 7.448276

铅钡 23.44828 16.551724

➤ 结论：风化状态与玻璃类型有关、与颜色无关、与纹饰无关。



问题1-2A（参考）

- 用CLR 变换后的数据比较风化前后哪些成分发生显著变化：方差分析或者化学成分对风化状态哑变量进行回归。
- 结论（高钾类）：
 - 风化会引起高钾类样本 SiO_2 成分比例的显著变化， p 值小于0.05；并会一定程度上引起 K_2O 、 CuO 成分比例的变化， p 值分别为0.06269 和0.0629。
 - 由线性模型一次项系数可知，表面风化引起高钾类样本 SiO_2 、 CuO 成分比例的增加， K_2O 成分比例的减少。



问题1-2B（参考）

- 用CLR 变换后的数据比较风化前后哪些成分发生显著变化：方差分析或者化学成分对风化状态哑变量进行回归；
- 结论（铅钡类）：
 - 风化会引起铅钡类样本 SiO_2 、 Na_2O 、 K_2O 、 CaO 、 Al_2O_3 、 PbO 、 P_2O_5 成分比例的显著变化， p 值均小于0.05。
 - 由线性模型一次项系数可知，表面风化引起铅钡类样本 SiO_2 、 Na_2O 、 K_2O 、 Al_2O_3 成分比例的减少， CaO 、 PbO 、 P_2O_5 成分比例的增加。





问题1-3参考

- 假设中心对数比变换后数据服从正态分布，考虑两个风化与未风化两个总体 $CLR(X)$, $CLR(Y)$ ，分别统计其均值和方差；

$$\begin{cases} CLR(X) \sim N(\mu_x, \sigma_x^2) \\ CLR(Y) \sim N(\mu_y, \sigma_y^2) \\ CLR(Y) = \mu_y + \frac{\sigma_y}{\sigma_x} (CLR(X) - \mu_x) \end{cases}$$


- 给定风化数据 $CLR(X)$ ，用上面的公式预测未风化 $CLR(Y)$ ，然后用 CLR 反变换退回成分数据：



问题2-1：变量初选

➤ 分组直方图比较，可以看到：不重要化学成分主要包括： P_2O_5 、 SrO 、 SnO_2 、 SO_2

##	类型	SiO2	Na2O	K2O	CaO	MgO	Al2O3	Fe2O3
## 1	高钾	69.19771	0.7125175	9.511526	5.439698	1.1037244	6.735561	1.9696321
## 2	铅钨	55.80345	1.7291987	0.229233	1.344180	0.6542665	4.547970	0.7612982
##		CuO	PbO	BaO	P2O5	SrO	SnO2	SO2
## 1	高钾	2.500060	0.4204066	0.6114364	1.426217	0.04744981	0.21140815	0.1126576
## 2	铅钨	1.480204	22.5656138	9.2832203	1.100691	0.27561594	0.05615964	0.1688948







问题2-1：可视化

➤ 去除不重要成分后的UMAP可视化

原始数据（去除不重要成分）可视化图



clr变换后数据（去除不重要成分）可视化图




中国大学生在线
dxs.moe.gov.cn



问题2-2：变量选择（参考）

- 利用随机森林，采用“Mean Decrease Accuracy”和“Mean Decrease Gini”两个指标度量变量的重要性。
- 高钾和铅钡类的重要识别成分包括：PbO、BaO 和K₂O；





问题2-3：亚类划分（参考）

- 仍然在CLR变换后空间上进行计算；
- 聚类方法：k-means；
- 变量选择
 - 基于方差进行选择；
 - 结合聚类结果度量指标(比如：轮廓系数Silhouette Coefficient, CH分数Calinski Harabasz Score ,戴维森堡丁指数Davies Bouldin Score,邓恩指数Dunn Validity Index等)，采用类似于逐步回归的思想选择合适的变量集合。



问题2-3A：高钾类亚类划分

- CLR变换后数据，保留前九个化学成分，使得它们的方差和大于总方差的80%，则选择的典型化学成分可以为 Na_2O , CaO , BaO , K_2O , PbO , SnO_2 , MgO , SO_2 , Fe_2O_3 .
- 用k-means 进行聚类，分别取聚类数 k 从2 到6，用轮廓系数最大辅助亚类数的选择
- 但由于样本本身很少，不宜分得太细;

得到聚类结果，由评价指标轮廓系数来确定最佳聚类数

```
## [1] 0.17086031 0.28226342 0.33472670 0.31765760 0.09074751
```





问题2-3B：铅钡类亚类划分

- CLR变换后数据，保留前七个化学成分，使得它们的方差和大于总方差的80%，则选择的典型化学成分可以为 Na_2O 、 Fe_2O_3 、 P_2O_5 、 MgO 、 CuO 、 CaO 、 K_2O 。
- 用k-means 进行聚类，分别取聚类数 k 从2 到6; 用轮廓系数最大辅助亚类数的选择;

得到聚类结果，由评价指标轮廓系数来确定最佳聚类数

```
## [1] 0.2547101 0.2296880 0.2250428 0.2303311 0.2197610
```

故取聚类数为 2。





问题3A：预测模型

- 选取关键性指标进行判别，经上述分析，去除一些不重要的特征，如 P_2O_5 , SrO , SnO_2 , SO_2 . 针对风化与否这两种情况分开讨论。
- 对于未风化的训练样本通过随机森林算法进行训练，对测试样本进行预测；

```
## Confusion matrix:
```

```
##      高钾  铅钡  class.error
```

```
## 高钾    12     0             0
```

```
## 铅钡     0    23             0
```

```
## [1] "预测新样本所属类别："
```

```
##      1      3      4      8
```

```
## 高钾  铅钡  铅钡  铅钡
```

```
## Levels: 高钾 铅钡
```





问题3B：预测模型

- 对于风化的训练样本通过随机森林算法进行训练，对测试样本进行预测；
- 对四个风化的新样本，先根据问题一解答中的预测公式还原为未风化的样本之后，采用前面的未风化样本分类模型进行预测；
- 发现两种方法给出的分类结果是一致的。

```
## Confusion matrix:
##      高钾  铅钡  class.error
## 高钾      6    0            0
## 铅钡      0   26            0
```

```
## [1] "预测新样本所属类别："
##      2      5      6      7
## 铅钡  铅钡  高钾  高钾
## Levels: 高钾 铅钡
```




问题4：相关关系

- 中心对数比变换之后的数据计算相关系数；
- 采用相关性检验挑选出统计显著的相关关系；
- 当然还可以考虑其他相关性度量：比如Spearman相关，Distance Correlation, Mutual Information，等等。



问题4：高钾类相关矩阵


相关关系(c1r变换)-高钾





问题4：铅钡类相关矩阵

相关关系(c1r变换)-铅钡





问题4：显著关联关系

- 对于高钾样本： SiO_2 与 Al_2O_3 、 SnO_2 之间存在正相关，与 Fe_2O_3 之间存在负相关； Na_2O 与 P_2O_5 之间存在负相关； SrO 与 CaO 之间存在负相关； SnO_2 与 CuO 、 Fe_2O_3 存在负相关； SO_2 与 BaO 、 PbO 存在负相关； Fe_2O_3 与 CuO 存在正相关，相关性检验 p 值均小于 0.05。
- 对应铅钡样本： SiO_2 与 PbO 之间存在正相关，与 SrO 之间存在负相关； Na_2O 与 Fe_2O_3 、 P_2O_5 、 SnO_2 存在负相关； K_2O 和 Al_2O_3 存在正相关，和 CaO 存在负相关； CaO 与 CuO 、 BaO 存在负相关； MgO 与 SO_2 存在负相关； Fe_2O_3 与 CuO 存在负相关； CuO 与 BaO 存在正相关、与 SnO_2 负相关； PbO 与 BaO 正相关，相关性检验 p 值均小于 0.05。
- 可以看出，对于高钾玻璃， Fe_2O_3 与 CuO 存在正相关，而铅钡玻璃则相反。



4. 评阅综述

- 评阅总体情况
- 几个典型问题
 - 成分数据处理问题
 - 风化前化学成分预测问题
 - 亚类区分中的变量选择问题
 - 成分数据相关分析问题




评阅总体情况

- 总体来说，本题的答题情况不是太好，绝大部分论文都存在缺陷，在后面提到的几个典型问题上存在或多或少的不足，甚至是逻辑上的错误。
- 幸运的是，最后遴选出来三篇优秀论文：C155，C065，C229在几个典型问题上都有不错的表现。这三篇论文在大学生在线上公示过。

C155

- 考虑到了数据的成分性，对数据进行CLR变换，在变换后的数据上进行统计分析。
- 在分析风化程度与其它因素关系中，注意到了卡方检验的适用范围和Yate校正；
- 利用风化程度引入时间概念（未风化，轻度风化，中度风化，重度风化），聚类，对聚类中心点CLR变换后数据建立趋势模型 $f(t)$ ，通过平移量预测分化前，CLR逆变换保证了预测后的值满足定和限制；



- R型聚类选择变量：对14中化学成分进行聚类，每个类中选取代表变量，然后进行亚分类；



C65

- 考虑到了数据的成分性，对数据进行CLR变换，在变换后的数据上进行统计分析；
- 在分析风化程度与其它因素关系中，在不满足卡方检验的适用范围时采用Fisher检验代替；
- 采用均值差进行分布匹配预测风化前，暗含了等方差的假设；

$$\xi_{erode} + \Delta\xi_{mean} = \xi_{Predict}$$

- SVM分类得到比较简单的大类区分规律；
- 层次聚类+SVM类，层次聚类法分出亚类，然后用SVM给出简单的亚类区分规律
- 用SVM参数变化量度量样本对分类影响；



C229

- 考虑到了数据的成分性，对数据进行CLR变换，在变换后的数据上进行统计分析；
- Dirichlet回归预测风化前化学成分：本质上等价于等方差下的分布匹配；
- 偏最小二乘判别分析(PLS-DA)进行大类分类，计算变量的变量的投影重要性(VIP)，筛选对分类有影响特征： PbO 、 K_2O 、 BaO 和 SrO ；
- 亚类划分中，在聚类基础上再采用PLS-DA进行分类，筛选重要变量：发现对高钾玻璃亚类分类有影响特征为 K_2O 、 SiO_2 、 CaO 、 SnO_2 和 BaO ，对铅钡玻璃亚类分类有影响特征为 P_2O_5 、 CuO 、 Na_2O 和 Fe_2O_3



成分数据处理问题

- 本题的最大特点就是成分数据，尽管由于测量误差，每个样本的所有化学成分相加不是刚好为100%，但根据题目中所强调的，各化学成分之和应该处理成100%；
- 成分数据是在单纯形空间上取值，一般采用中心对数比变换(CLR)转换到低一维的欧氏空间；
- 由于要进行对数变换，没有观察数据的化学成分需要用一个小量(ϵ)加以填充，然后归一化成定和；



风化前化学成分预测

- 数据中只有风化后的数据，缺少风化前的数据与之配对，没有配对的学习样本来建立普通的预测模型。只能通过分布匹配，在比较强的假设下给出预测；
- 有同学将风化前后作为哑变量进行回归分析，本质上等价于等方差假设下的均值匹配方法；
- 有同学在上述模型的基础上，加入其他协变量(颜色，纹理等)建立多元回归模型，也是可以的，相当于利用其他协变量进行细分，本质上还是等价于均值匹配方法；
- 评阅中发现了大量论文，简单套用机器学习方法进行预测，是完全错误的；



亚类区分中的变量选择问题

- 选择变量后会影响样本之间距离的计算，从而会影响聚类结果；这是一个典型的无监督变量选择问题，相比于有监督的变量选择问题，相关的文献比较少；
- 有同学先做主成分分析，然后用几个主成分作为变量进行聚类，这个不是真正的变量选择；但根据主成分中变量的载荷系数选择主成分中载荷系数绝对值大的变量，有一定的道理；



成分数据相关性分析

- 成分数据上皮尔逊相关系数有偏负的倾向，不能准确反应化学成分绝对量之间的相关关系。举一个极端的例子，如果只有两个成分，绝对量为 y_1, y_2 ，归一化后得到成分 x_1, x_2 ， $x_1 + x_2 = 1$ ，那么 $PCC(x_1, x_2) = -1$ ；
- 可以借助于中心对数比变换(CLR)对绝对量相关关系加以估计；
- 本人课题组在成分数据相关矩阵估计、精度矩阵估计(网络推断)和差异矩阵估计有一定的研究，提出了几个算法(CCLasso, gCoda, CDTrace, CDTr, CodaLoss)，有兴趣的老师 and 同学请参考。



谢 谢!