

C题: NIPT的时点选择 与胎儿的异常判定

CUI Hengjian (崔恒建)

School of Mathematical Sciences, Capital Normal University

2025全国大学生数模赛题讲评经验交流会，深圳

2025.11.15

一、题目解读

- ▶ NIPT准确性由胎儿性染色体(男胎XY,女胎XX)浓度判断。孕期在10周~25周之间可以检测胎儿性染色体浓度,若男胎的Y染色体浓度达到或高于4%、女胎的X染色体浓度没有异常,则可认为NIPT的结果基本准确。
- ▶ 尽早发现不健康胎儿,早期发现(<12周)风险较低;中期发现(13-27周)风险高;晚期发现(>28周)风险极高。

- ▶ 男胎Y 染色体浓度与孕妇孕周数及BMI相关。通常根据孕妇BMI值进行分组分别确定NIPT时点。
- ▶ 每个孕妇的年龄、BMI、孕情等存在个体差异，不宜对所有孕妇采用简单的经验分组和统一的检测时点进行NIPT。
- ▶ 依据BMI对孕妇进行合理分组，确定各不同群组的最佳NIPT时点，可以减少某些(特别是肥胖) 孕妇因胎儿不健康所带来的潜在风险。

► 问题1:

- ★ 分析Y染色体浓度与孕妇的孕周数和BMI等指标的**相关特性**
- ★ 给出相应的关系模型，检验其显著性。

► 问题2:

- ★ 对男胎孕妇的BMI进行**合理分组**，给出每组的BMI **区间** 和最佳NIPT **时点**，使得孕妇的**潜在风险最小**
- ★ 分析检测误差对结果的**影响**。



► 问题3:

- ★ 综合考虑身高、体重、年龄等因素、检测误差和胎儿的Y染色体浓度**达标比例**，根据男胎孕妇的BMI，给出合理分组以及每组的最佳NIPT时点，使得孕妇**潜在风险最小**
- ★ 分析检测误差对结果的**影响**。

► 问题4:

- ★ 以女胎孕妇的21号、18号和13号染色体非整倍体（**AB列**）为**判定结果**，综合考虑X染色体及上述染色体的Z值、GC含量、读段数及相关比例，BMI等因素
- ★ 给出女胎**异常的判定方法**。

- 统计优化与异常判定实际问题;
- 数据噪音大, 不确定性高;
- **非纯数据处理或机器学习问题!**

二、解题思路

问题1. 相关特性分析与关系模型

► 1.1. Y 染色体浓度 y (因变量); BMI, 孕周GA




图1. BMI与Y浓度关系




图2. GA与Y浓度关系

- 相关指标: Pearson, Spearman, Kendall 等

指标	(BMI,y)	(GA,y)	(BMI,GA)
P	-0.151(6.1e-7)	0.127(5.1e-5)	0.150(7.2e-7)
S	-0.154(3.4e-7)	0.085(5.2e-3)	0.137(6.6e-6)
K	-0.105(2.6e-7)	0.060(3.6e-3)	0.093(5.8e-6)

$P(\text{BMI},y) = -0.191$ (logbit)

► 1. 探索性的简单回归模型

$$y = \alpha + \beta \cdot BMI + \epsilon$$

$$\hat{\alpha} = 0.132^{***}, \quad \hat{\beta} = -0.002^{***}, \quad R^2 = 0.023$$

$$y = \alpha + \gamma \cdot GA + \epsilon$$

$$\hat{\alpha} = 0.06^{***}, \quad \hat{\gamma} = 0.001^{***}, \quad R^2 = 0.016$$

$$y = \alpha + \beta \cdot BMI + \gamma \cdot GA + \epsilon$$

$$\hat{\alpha} = 0.119^{***}, \quad \hat{\beta} = -0.002^{***}, \quad \hat{\gamma} = 0.001^{***}, \quad R^2 = 0.046$$

- y 与BMI 负相关、与GA正相关.

▸ 2. 分段线性优化(全局非线性)模型

将BMI分成若干连续区间 $[a_{g-1}, a_g)$, $g = 1, \dots, G$, 其中 G, a_g 可预先给定,

$$y = \alpha + \sum_{g=1}^G \beta_g I\{a_{g-1} \leq BMI < a_g\} + \gamma \cdot GA + \epsilon \quad (1)$$

或

$$y_g = \alpha_g + \gamma_g \cdot c(GA) + \eta^T \cdot sd(W) + \epsilon_g, \quad (2)$$
$$a_{g-1} \leq BMI < a_g.$$

W 为其他因素(问题1中 η 可设为0)。

- 比如取 $G = 3$, $a_0 = BMI_m$, $a_1 = 30.5$, $a_2 = 36$, $a_3 = BMI_M$. 对模型(1), BMI 3个区间所对应与Y浓度的线性关系:




图3. 分组BMI与Y浓度关系

- ▶ BMI 3个区间所对应的孕周截距与斜率分别为:

$(0.0557, 0.0016),$

$(0.0633, 0.0008),$

$(0.0099, 0.0025).$

- ▶ 进一步验证 y 与BMI 负相关、与GA正相关

▶ 3. 非线性混合效应模型(确定分组)

$$y_{ij} = \alpha + u_i + \sum_{g=1}^G \beta_g I\{a_{g-1} \leq BMI_{ij} < a_g\} \\ + (\gamma_1 + v_i) c(GA)_{ij} + \epsilon_{ij}, \quad (3)$$

其中 i 为孕妇, j 为其第 j 次检测, β, γ 为群体平均斜率(边际效应); $u_i \sim N(0, \sigma_u^2)$ 为随机截距, 刻画不同孕妇的基线不同; $v_i \sim N(0, \sigma_v^2)$ 是 GA_i 的随机斜率, 反映第 i 个孕妇的个体差异项, 观测误差 $\epsilon_{ij} \sim N(0, \sigma^2)$ 。

如取上述BMI分组 $G = 3$, 则有:

固定效应	估计值	标准差	检验 t 值
α	0.0763	0.0016	47.941***
β_1	0.0065	0.0029	2.272*
β_2	0.0019	0.0026	0.729
β_3	-0.0084	0.0042	-1.983*
γ_1	0.0035	0.0002	15.91***

- 计算效应方差与总方差之比 R^2 , 量化不同来源的变异对响应变量总变异的贡献程度, 衡量模型解释力, 固定效应解释力相对较弱.

随机效应总方差	8.35e-4
残差方差	1.77e-4
总方差	1.043e-3
条件 R^2 (固定+ 随机效应解释力)	0.8303
边际 R^2 (仅固定效应解释力)	0.0297

如果BMI分点取为30.5, 36, $G = 3$, 且 $\gamma_2 = 0$.




图3. G1,G2, G3: Y浓度与孕周关系

问题2. BMI分组及每组最佳NIPT时点

► BMI 分组:

模型(2), (3)可用于最佳NIPT时点确定。以模型(2)为例进行整体统计优化BMI分组.

$$y_g = \alpha_g + \gamma_g \cdot c(GA) + \epsilon_g, \quad a_{g-1} \leq BMI < a_g. \quad (2)$$

其中 $g = 1, 2, \dots, G$.

- G , 区间分点 a_g 皆未知, 需要由统计数据优化确定, 即: 组内差异(同一BMI区间内, 用孕周拟合染色体浓度)尽量小, 组间差异(不同BMI区间所拟合曲线的差异)尽量大。

- ▶ 记 $\mathcal{A}_G = \{a_g : 1 \leq g \leq G \leq G_0, BMI_m \leq a_g \leq BMI_M\}$. 给定 $A \in \mathcal{A}_G$, 通过LS拟合得 $\{\alpha_g(A), \gamma_g(A)\}$. 令:

$$w_g(A) = \frac{1}{N} \#\{i : BMI_i \in [a_{g-1}, a_g), 1 \leq i \leq N\},$$

$$\bar{\alpha}(A) = \sum_{g=1}^G w_g(A) \alpha_g(A), \quad \bar{\gamma}(A) = \sum_{g=1}^G w_g(A) \gamma_g(A),$$


$$Q(A) = \sum_{g=1}^G w_g [(\alpha_g - \bar{\alpha})^2 + (\gamma_g - \bar{\gamma})^2].$$

得到: $\hat{A}_G = \operatorname{argmax}_{A \in \mathcal{A}_G} Q(A),$

其中 G 通过惩罚方法确定最优:

$$G = \operatorname{argmax}_{1 \leq G \leq 10} [\max_{A \in \mathcal{A}_G} Q(A) - \lambda(G - 1)].$$

- 计算结果：划分为4组($G = 4$), 分别是:
 - < 28.48 ($n = 49$),
 - $[28.48, 30.57)$ ($n = 292$),
 - $[30.57, 36.04)$ ($n = 626$),
 - ≥ 36.04 ($n = 111$).



► 最优时点确定:

在BMI 最优分组内, 用线性分位数回归描述 Y 随孕周的变化

$$Q_{g\tau}(Y|GA) = \alpha_{g\tau} + \gamma_{g\tau}GA_g, \quad \tau \in \{0.20, 0.30\}.$$

其中 $\tau = 0.30, 0.20$ 分别对应约70%, 80% 个体可达标的时点。

用R语言中“rq” 命令计算参数估计 $\hat{\alpha}_{g\tau}, \hat{\gamma}_{g\tau}$.

► 简单求解

$$\hat{\alpha}_{g\tau} + \hat{\gamma}_{g\tau}GA_g = 0.04,$$

得到该组在置信水平 $1 - \tau$ 下的最早起测孕周 $\hat{GA}_{g\tau}$ (并限制在该组的观测孕周区间内).

$$\begin{aligned}\hat{GA}_{g\tau} = \min\{GA_g : \hat{\alpha}_{g\tau} + \hat{\gamma}_{g\tau}GA_g \geq 0.04, \\ GA_g \in [GA_{gm}, GA_{gM}]\}\end{aligned}$$


- 进一步构建融入孕周风险的优化模型:

$$\begin{aligned}\hat{GA}_{g\tau} &= \operatorname{argmin}\{[\hat{\alpha}_{g\tau} + \hat{\gamma}_{g\tau+}GA_g - 0.04]^2 \\ &\quad + \lambda \cdot \operatorname{Risk}(GA_g)\} \\ \text{s.t.} \quad &GA_g \in [GA_{gm}, GA_{gM}],\end{aligned}$$

其中 $\operatorname{Risk}(t)$ 为S型风险函数, 如:

$$\operatorname{Risk}(t) = \operatorname{Clip}\left(\frac{r(t) - r(10)}{r(40) - r(10)}; 0, 1\right),$$

$$\begin{aligned}
 r(t) &= b_1 B_E(t) + b_2 B_M(t) + b_3 B_L(t), \\
 B_L(t) &= \max(t - 28, 0), \quad B_E(t) = \min(t, 12), \\
 B_M(t) &= \max(\min(t, 28) - 12, 0), \\
 b_1 : b_2 : b_3 &= 1 : 3 : 6, \lambda > 0 \text{ 为调节参数.}
 \end{aligned}$$



计算结果:

BMI 组	$\hat{G}A$ (周, $\tau = 0.30$)	$\hat{G}A$ (周, $\tau = 0.20$)
G1	11.60	12.30
G2	12.83	13.20
G3	14.00	15.90
G4	17.79	21.90

- ▶ 中间两组BMI更接近普遍人群范围；两端分组呈现不同情形，极端BMI人群检测时间波动较大。
- ▶ 最高BMI组 (> 36) 要到17.8周 ($\tau = 0.30$) 才越过4%，这与高BMI可能带来的母体cfDNA稀释、使胎儿比例偏低的常见现象相一致；
- ▶ 最低BMI组 (< 28.5) 在11周下分位仍略低于4%，需到12周左右才达标。

检测误差分析:

- ▶ 在已确定的BMI 最优分组(< 28.5 , $28.5 - 30.6$, $30.6 - 36.0$, ≥ 36)基础上, 不改变分组与模型, 只给“最早达标孕周”配上误差与不确定性。
- ▶ 考虑到同一孕妇可能多次检测、观测并非独立, 按“孕妇ID”做簇级(cluster) bootstrap: 每次整簇重采样(或增加小扰动), 重复拟合并重算 $\hat{GA}_{g\tau}$, 以获得95% 置信区间。

- ▶ 检测误差会把“最早达标时间”整体向后推，且BMI 越高推得越多。建议把“单个最早时点”转化为“起测+复检”：

(1) $BMI < 36$: 在11 – 12 周安排首次NIPT; 若 $< 4\%$, 2 – 4 周后复检(必要时再次复检)。基准 $\hat{GA} (\tau = 0.30(0.20))$ 可作为“多数能过”的参考。

(2) $BMI \geq 36$: 若使一次通过概率更高, 建议 18 周左右再检; 或11 – 12 周先检并预设2 – 4 周后复检。

问题3. 基于达标概率的**BMI**分组 及每组最佳**NIPT**时点

- ▶ 需要估计“首次 $y \geq 4\%$ 的孕周 GA ” 的分布，并在不同**BMI**人群上给出 $F(t) = Pr(GA \leq t)$ (或生存函数 $S(t) = 1 - F(t)$) 及分位点 t_q (如 $q = 70\%, 80\%$).
- ▶ 同一孕妇存在多次检测，真实的首次达标时间只知落在相邻两次采样孕周之间，属于区间删失(interval censoring) 问题.

- ▶ 以孕妇为单位构造一条观测 $(L_i, R_i]$, 若在孕周序列中首次出现 $Y \geq 0.04$, 则取上一次与本次孕周形成的区间; 若首条即 $Y \geq 0.04$, 则为左删失 $(\varepsilon, R_i]$; 若始终 $Y < 0.04$, 则为右删失 $(L_i, +\infty)$ 。
- ▶ 给出 $S(t)$ 的估计 $\hat{S}(t)$, 计算“在任意孕周 t 已达标” 的概率 $\hat{F}(t) = 1 - \hat{S}(t)$ 。

删失数据处理示例:

孕妇代码	删失类型	原因
A001	无删失	首次检测(11w+6)未达标(0.038),第二次(15w+6)达标(0.060),达标孕周在(11w+6,15w+6]区间内
A002	左删失	首次检测(13w+6)即达标(0.059),真实达标孕周 $< 13w+6$,无法精确观测
A003	左删失	首次检测(13w)即达标(0.055),真实达标孕周 $< 13w$,无法精确观测
A004	无删失	首次检测(11w)未达标(0.039),第二次(15w+6)达标(0.059),达标孕周在(11w,15w+6]区间内
A005	无删失	首次检测(12w+2)未达标(0.021),第二次(15w+2)达标(0.069),达标孕周在(12w+2,15w+2]区间内
A006	左删失	首次检测(12w+1)即达标(0.065),真实达标孕周 $< 12w+1$,无法精确观测
A007	右删失	四次检测中末次检测(23w+5)未达标(0.022),后续无检测记录,真实达标孕周 $> 23w+5$

- 构建区间删失的**Cox** 比例风险模型:

$$\lambda(t|W) = \lambda_0(t) \exp\{W^T \beta\},$$

其中 $S_0(t) = \exp\{-\int_0^t \lambda_0(s)ds\}$, $\lambda_0(t)$ 为基线风险函数, W 为协变量(年龄、身高、体重等), 则生存函数 $S(t|W)$ 的表达:

$$S(t|W) = \exp(-\int \lambda(u|W)du) = S_0(t)^{\exp(W^T \beta)}.$$

- 利用R语言包中的 *icenReg* 程序, 给出 $S(t|W)$ 的估计 $\hat{S}(t|W)$ 。

► BMI分组:

类似问题2, 定义 $Q(A)$ 为

$$Q(A) = \sum_{g=1}^G w_g (p_g - \bar{p})^2,$$

其中 $p_g = P(Y \geq 4\%, BMI \in [a_{g-1}, a_g])$ 或(比例), $\bar{p} = \sum_{g=1}^G w_g p_g$,

得到: $\hat{A}_G = \operatorname{argmax}_{A \in \mathcal{A}_G} Q(A),$

其中: $G = \operatorname{argmax}_{1 \leq G \leq 10} [\max_{A \in \mathcal{A}_G} Q(A) - \lambda_1 (G - 1)].$


- 在男胎样本中，按BMI分组给出各组最佳NIPT检测时点：“最佳”定义为在“检测成功率”与“孕期安全性”之间取得最优权衡的时间点。即优化目标(损失)函数：

$$J(t) = -\log(1 - \hat{S}(t|W)) + \lambda_2 Risk(t).$$

- 各BMI组的最佳检测时点： $\hat{G}A_q = \operatorname{argmin}_{t \in [12, 30]} J(t).$

计算结果($\lambda_1 = 0.00045, \lambda_2 = 0.80$) :

BMI 组		$\hat{G}A$ (周)
G1	< 30.4	13.3
G2	$[30.4, 32.4)$	13.5
G3	≥ 32.4	17.1



检测误差分析:

- 误差发生在观测量 y ($\{y \geq 0.04\}$), 同一孕周重复取样的 y 会有误差。建立误差模型:

$$Y^{(obs)} = y^{(true)} + \epsilon, \quad \epsilon \sim N(0, \sigma^2)$$

其中 σ 用分位回归残差的MAD 估计(稳健)。

最优BMI 分组不变, 只对观测量 y 加噪声, 重建 $(L, R]$, 重拟合Cox, 并重复计算各组的 $\hat{G}A_g$.

- ▶ 基准各组 $\hat{G}A_g$ 为13.3/13.5/17.1 周。在仅对观测量 Y 加入 $N(0, \sigma^2)$ 扰动($\sigma \approx 0.0234$) 并重复200 次后, 三组 $\hat{G}A_g$ 的均值约为14.3/14.7/17.6 周。
- ▶ 相比较基准, 在噪声扰动下, 最佳检测时点出现轻微延后。

问题4: 女胎异常的判定方法

记 $X \in \{L, M, N, O, AA\}$, p 分位数:

$$Q_p(X) = \inf\{x : F_X(x) \geq p\}.$$

采用“中心90% 截断”的对称门槛.

- ▶ 对“越大越好”指标（如总读段数L、比对比例M、唯一比对比例O）保留 $[\hat{Q}_{0.05}(X), +\infty)$;
- ▶ 对“越小越好”指标(如重复率N, 过滤比例AA)保留 $(-\infty, \hat{Q}_{0.95}(X)]$.

- ▶ 以AB 列作为标签, 即依据AB 列标注的chr13, chr18, chr21 非整倍体阳性/阴性结果, 采用判别分析(逻辑回归分类, 主成分分析等, 给出异常与正常样本差异性指标)构建女胎异常判定模型.

1. 数据:

- 总样本量为604 例，其中AB 列标签显示chr13 阳性24 例, chr18 阳性46 例, chr21 阳性13 例, 经QC 同“中心90% 截断”标准:

$$L \geq Q_{0.05}(L), M \geq Q_{0.05}(M), O \geq Q_{0.05}(O),$$

$$N \leq Q_{0.95}(N), AA \leq Q_{0.95}(AA).$$

- 通过QC 的样本共501 例, 计算稳健标准化z值:

$$z = \frac{X - med(X)}{MAD(X)},$$

其中, $MAD = med\{|X - med(X)|\}$.

2. 模型构建:

- ▶ 针对chr13、chr18、chr21 三条染色体, 分别基于AB 列标签进行逻辑回归训练, 以染色体Z 值为主要特征, 结合质量与个体协变量

(GC 含量, $\log(L)$, M , N , O , AA , BMI , ZX),

按目标假阳率 (99% 和99.5%) 估计对应的 Z_{lo} 阈值(对应约99% 特异度), Z_{hi} 阈值(对应约99.5% 特异度)。

3. 质量分层阈值:

- 将样本按综合质量指数 QI 分为良好 (good)、典型 (typ)、临界 (marg) 三档, 分别计算各档的双阈值。其中, QI 计算方式为:

$$QI_k = z(M) + z(O) + z(\log(L)) \\ - z(N) - z(AA) - z(|GC_k - med(GC_k)|),$$

以20% 和80% 分位为界划分三档。

- 样本所属的良好、典型或临界质量档，匹配对应质量档 Z 的阈值 Z_{lo} (约99% 特异度) 和 Z 的阈值 Z_{hi} (约99.5% 特异度) 计算结果:

chr13

分类	$Z_{lo} (Sp \geq 99\%)$	$Z_{hi} (Sp \geq 99.5\%)$
good	3.223	3.477
typ	2.896	3.145
marg	2.429	2.671

指标	TP	TN	FP	FN	$Se.$	$Sp.$
CM_{lo}	12	484	4	1	0.9231	0.9918
CM_{hi}	11	486	2	2	0.8462	0.9959

chr18

分类	$Z_{lo} (Sp \geq 99\%)$	$Z_{hi} (Sp \geq 99.5\%)$
good	2.904	3.119
typ	2.721	2.931
marg	2.527	2.732

指标	TP	TN	FP	FN	$Se.$	$Sp.$
CM_{lo}	32	465	4	0	1	0.9915
CM_{hi}	31	467	2	1	0.9688	0.9957

chr21

分类	$Z_{lo} (Sp \geq 99\%)$	$Z_{hi} (Sp \geq 99.5\%)$
good	2.298	2.310
typ	2.122	2.133
marg	1.966	1.976

指标	TP	TN	FP	FN	$Se.$	$Sp.$
CM_{lo}	10	487	4	0	1	0.9919
CM_{hi}	10	489	2	0	1	0.9959

4. 判定应用:

- ▶ 若样本 Z 值低于该质量档的 Z_{lo} 阈值, 判定为阴性区, 女胎该染色体非整倍体异常风险较低;
- ▶ 若 Z 值介于该质量档的 Z_{lo} 阈值与 Z_{hi} 阈值之间, 判定为观察区, 建议复检以明确情况;
- ▶ 若 Z 值高于该质量档的 Z_{hi} 阈值, 判定为阳性区, 提示异常风险较高, 需深入检查。

参赛总结

问题1

- ▶ 参赛学生能意识到该问题不能只直接利用Pearson相关系数(线性探索), 使用Spearman相关系数等非线性相关度量, 少部分队伍很好地利用随机效应或分组机制来衡量相关关系, 答题情况普遍较为完整。
- ▶ 大部分队伍直接利用多元线性回归模型对复杂数据进行线性拟合, 缺乏可解释性。

问题2与问题3

- ▶ 呈递进关系，均需根据考虑孕周对BMI有序区间分组的差异性 or 浓度超过4%的概率差异来划分BMI区间，并融合达标概率和孕妇潜在风险角度确定每组的最佳NIPT时点。少部分队伍给出了分组的差异性指标及优化目标函数确定BMI分点和最优时点，且与实际经验相符合。
- ▶ 超半数队伍选择K-means、层次聚类等经典方法直接对BMI数据本身进行聚类，未考虑协变量孕周的变化对BMI有序分组的影响，以及分组的差异性建模，整体答题情况较为一般。

问题4

- ▶ 各参赛队伍多选择机器学习算法如XGBoost、逻辑回归等对女胎染色体异常数据进行分类建模，忽略了异常判定与普通分类的区别，绝大多数队伍此题完成效果并不理想，未能给出合理的落地判定方案。
- ▶ 综合来看大部分参赛队伍在建模过程中表现出较好的基础能力，逻辑性与统计意识相比以往有所提升。有少数队对各问均选择深度学习算法直接建模，但仍存在“数据变动、方法固化”的现象。需加强根据不同数据特点灵活选择合适处理方法的能力，提高模型的适应性与可解释性。

注 意

- ▶ 对问题附件中的数据无需进行清洗、删补、平衡等常规的、无益于问题解决的预处理。
- ▶ 侧重于统计分析和优化方法，纯粹机器学习或大数据分析方法及评价标准并不适合解决该问题。

数学建模

- ▶ 一种语言、思维方法;
科学理性解决实际问题(做事)的范式
- ▶ 一次建模, 终身收益

Thanks!